SR3 Implementation

Image Super Resolution via Iterative Refinement

Université de Toulouse

Erwann Havot
Maxime Rieux

SOMMAIRE

1. Introduction et contexte
2. Modèle de Diffusion Conditionnel
3. Architecture et Méthodologie
4. Résultats
5. Conclusion

Introduction et Contexte

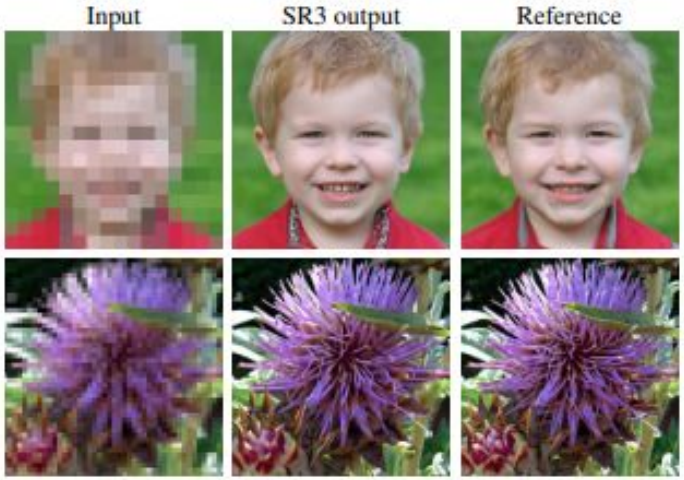

Figure 1: Two representative SR3 outputs: (top) 8× face super-resolution at 16×16→128×128 pixels (bottom) 4× natural image super-resolution at 64×64→256×256 pixels.

- Utilisation d'une approche par modèles de diffusion probabilistes
- Ecrit par : Google Research, Brain Team, 2021

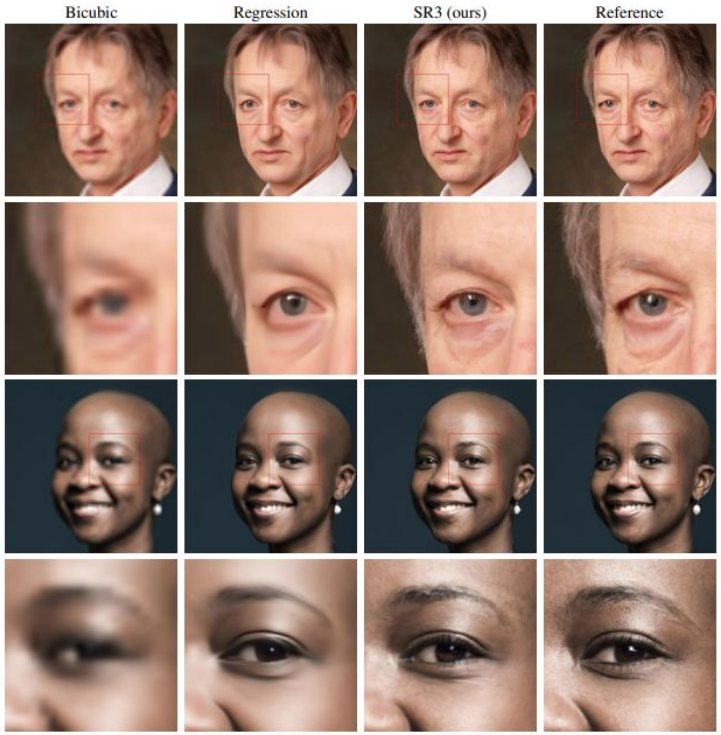

Figure 4: Results of a SR3 model (64×64 → 512×512), trained on FFHQ, and applied to images outside of the training set, along with enlarged patches to show finer details. Additional results are shown in Appendix C.1 and C.2.

Super-Résolution : Générer une image haute résolution cohérente à partir d'une entrée basse résolution

Le problème : Un problème inverse "mal posé"

Contraintes : Une seule image basse résolution peut correspondre à plusieurs images haute résolution possibles.

Les limites des modèles actuels :

Modèles de Régression (MSE) :

- Visent la moyenne des possibilités.
- Résultats : Images floues, manque de hautes fréquences (détails fins).

GANs (Generative Adversarial Networks) :

- Instabilité de l'entraînement
- Hallucinations incohérentes avec l'entrée (ex : changement d'identité)

=> Manque de Hautes-Fréquences, de détails

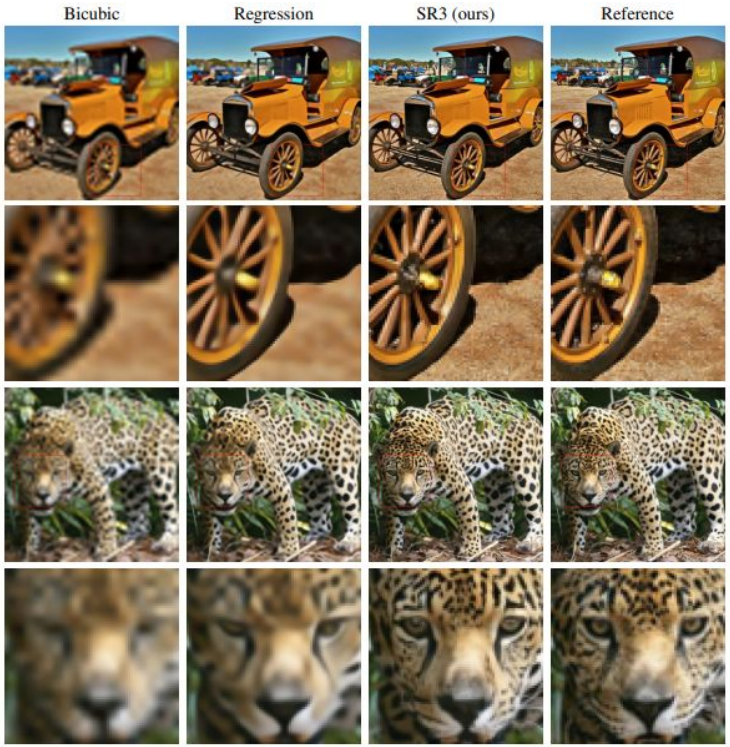

Figure 3: Results of a SR3 model (64×64 → 256×256), trained on ImageNet and evaluated on two ImageNet test images. For each we also show an enlarged patch in which finer details are more apparent. Additional samples are shown in Appendix C.3 and C.4.

La solution SR3

Idée : Processus de débruitage itératif stochastique

Fonctionnement :

1. **Départ :** Bruit Gaussien pur
2. **Processus itératif :** Raffinement progressif conditionné par l'image source bruitée (notée x dans la figure)
3. **Résultat :** Image haute résolution réaliste

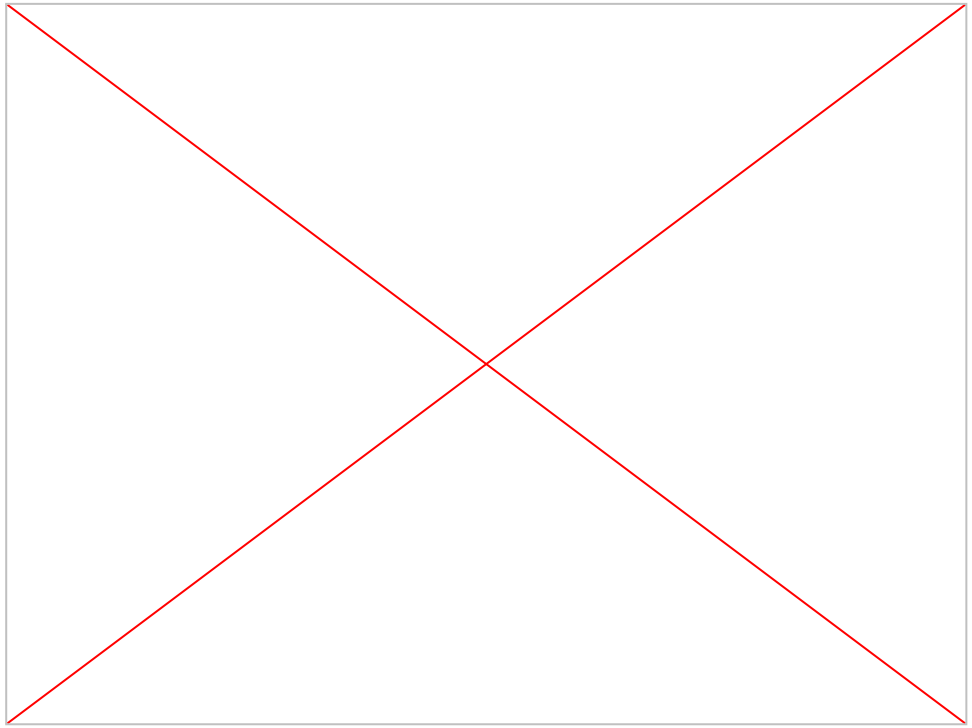

Modèle de Diffusion Conditionnel

Concept de diffusion

=> ; Processus Direct (Forward q) : Destruction progressive de l'image. On ajoute du bruit Gaussien étape par étape jusqu'à obtenir du "bruit pur"

<= ; Processus Inverse (Reverse p) : Le but du modèle. Partir du bruit et apprendre à le retirer itérativement pour retrouver une image structurée

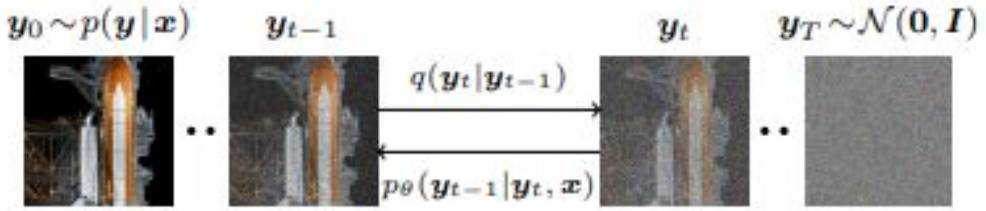

Figure 2: The forward diffusion process q (left to right) gradually adds Gaussian noise to the target image. The reverse inference process p (right to left) iteratively denoises the target image conditioned on a source image x. Source image x is not shown here.

Génération conditionnelle

Génération Conditionnelle : On ne veut pas générer n'importe quel visage, mais celui qui correspond à l'entrée x (Image Basse Résolution d'entrée)

Le Guide : À chaque étape du débruitage, le modèle "regarde" l'image source x pour s'en rapprocher

Formulation : Le modèle apprend la distribution conditionnelle p(y|x)

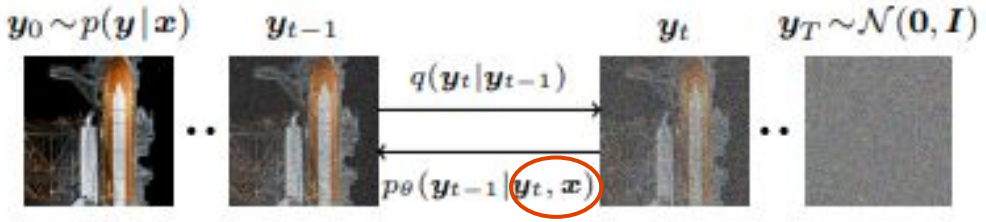

Figure 2: The forward diffusion process q (left to right) gradually adds Gaussian noise to the target image. The reverse inference process p (right to left) iteratively denoises the target image conditioned on a source image x. Source image x is not shown here.

Architecture et Méthodologie

Réseau de neurones utilisé

Modèle utilisé : un U-Net, réseau en forme de U

Structure :

- **Encoder (Descente) :** Comprime l'image pour extraire les caractéristiques, les features afin de comprendre le contexte global
- **Decoder (Montée) :** Reconstruit l'image à la taille originale, décompresse l'image afin de travailler les détails
- **Skip Connections :** Relient l'encodeur au décodeur pour ne pas perdre les détails fins, ces connexions permettent transférer les détails fins directement du début à la fin du réseau

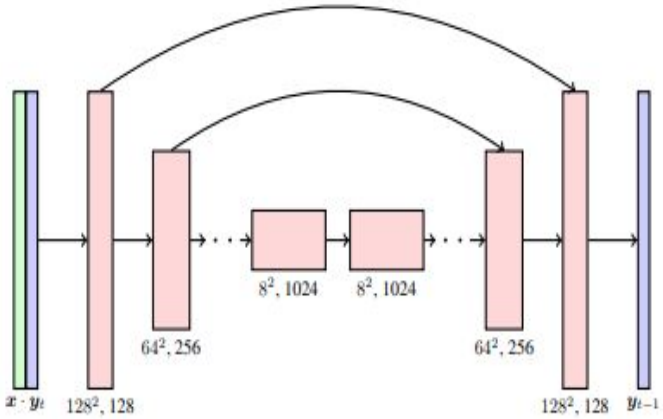

Figure A.1: Description of the U-Net architecture with skip connections. The low resolution input image x is interpolated to the target high resolution, and concatenated with the noisy high resolution image y_t. We show the activation dimensions for the example task of $16 \times 16 \rightarrow 128 \times 128$ super resolution.

Les données d’entrée du réseau

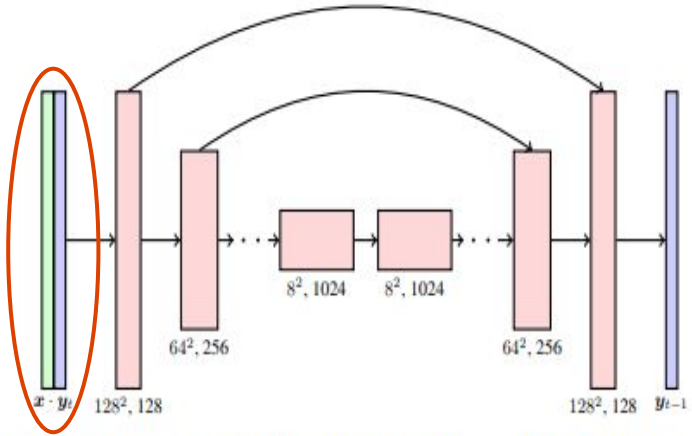

Figure A.1: Description of the U-Net architecture with skip connections. The low resolution input image x is interpolated to the target high resolution, and concatenated with the noisy high resolution image y_t. We show the activation dimensions for the example task of $16 \times 16 \rightarrow 128 \times 128$ super resolution.

Le Problème : Comment donner l'image Basse Résolution (16 x 16) à un réseau qui travaille en Haute Résolution (128 x 128) ?

La Solution SR3 :

1. **Upsampling :** On agrandit l'image basse résolution à la taille cible via une interpolation simple (Bicubique).
2. **Concaténation :** On "colle" cette image agrandie avec l'image bruitée actuelle (y_t).

Résultat : Le réseau reçoit une entrée à 6 canaux (3 pour le bruit + 3 pour la condition).

Apprentissage du modèle

/!\ Le modèle ne prédit pas l'image finale directement

Son objectif : Prédire le bruit présent dans l'image courante

Entraînement : On choisit une étape t au hasard pour entraîner le modèle à gérer tous les niveaux de bruit, du "bruit léger" au "bruit total"

=>Le modèle doit être capable de travailler à tous les niveaux de destruction

Fonction de Perte (Loss) : On compare le bruit prédit au bruit réel

Algorithm 1 Training a denoising model f_θ

1: **repeat**
2: $(\boldsymbol{x}, \boldsymbol{y}_0) \sim p(\boldsymbol{x}, \boldsymbol{y})$
3: $\gamma \sim p(\gamma)$
4: $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
5: Take a gradient descent step on
$\nabla_\theta \left\| f_\theta(\boldsymbol{x}, \sqrt{\gamma}\boldsymbol{y}_0 + \sqrt{1-\gamma}\boldsymbol{\epsilon}, \gamma) - \boldsymbol{\epsilon} \right\|_p^p$
6: **until** converged

$$\mathbb{E}_{(\boldsymbol{x},\boldsymbol{y})}\mathbb{E}_{\boldsymbol{\epsilon},\gamma}\left\| f_\theta(\boldsymbol{x}, \underbrace{\sqrt{\gamma}\,\boldsymbol{y}_0 + \sqrt{1-\gamma}\,\boldsymbol{\epsilon}}, \gamma) - \boldsymbol{\epsilon} \right\|_p^p$$

La génération en cascade

Le Défi : Entraîner un seul modèle pour passer directement de 64 x 64 à 1024 x 1024 est trop complexe et coûteux

La Solution Cascade de SR3: Enchaîner plusieurs modèles plus petits spécialisés

Modularité : On peut entraîner chaque modèle indépendamment en parallèle.

Simplicité : Chaque modèle résout une tâche plus simple (=> moins de paramètres nécessaires)

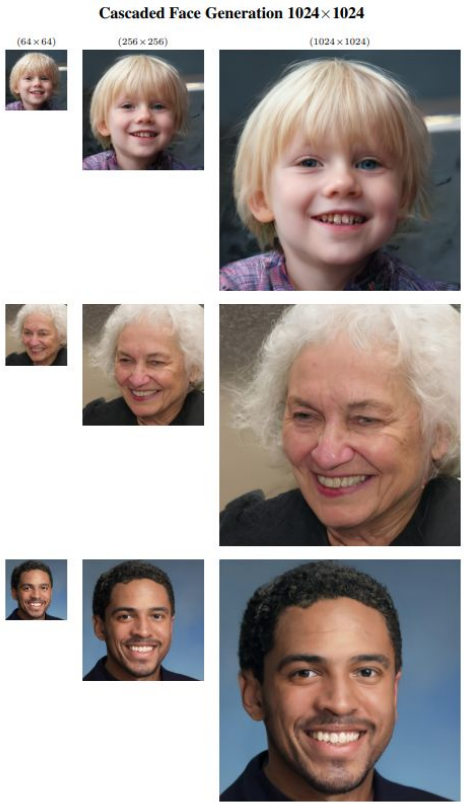

Figure C.6: Cascaded generation on faces using an unconditional model chained with two SR3 models.

Résultats

Métriques d'erreurs inadaptées

/! Les modèles de régression (MSE) obtiennent souvent de meilleurs scores PSNR/SSIM que SR3

La Raison : Ces métriques pénalisent le moindre décalage de pixel

Conclusion : PSNR et SSIM favorisent le flou et ne reflètent pas la perception humaine

=> utilisation d'évaluateurs humains

Model	FID ↓	IS ↑	PSNR ↑	SSIM ↑
Reference	1.9	240.8	-	-
Regression	15.2	121.1	**27.9**	**0.801**
SR3	**5.2**	**180.1**	26.4	0.762

Table 2: Performance comparison between SR3 and Regression baseline on natural image super-resolution using standard metrics computed on the ImageNet validation set.

Evaluation Humaine

Méthode : Test "2-Alternative Forced Choice" (2AFC)

La Question posée aux humains : "Quelle image est la vraie photo ?" (comparaison SR3 vs Vérité Terrain)

Le "Fool Rate" (Taux d'erreur) :

- Un score de **50%** signifie que l'humain devine au hasard → L'image générée est indiscernable du réel

=> SR3 Atteint un Fool Rate proche de **50%** (~47-54%)

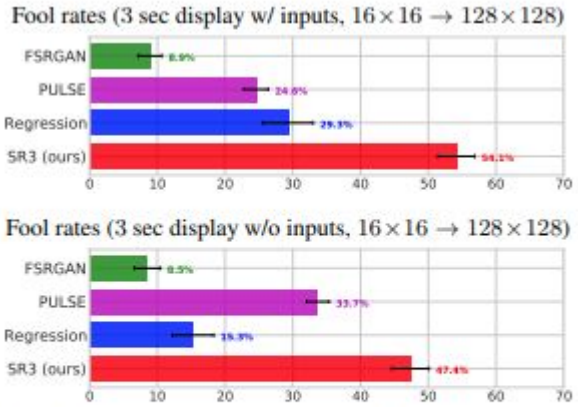

Figure 6: Face super-resolution human fool rates (higher is better, photo-realistic samples yield a fool rate of 50%). Outputs of 4 models are compared against ground truth. (top) Subjects are shown low-resolution inputs. (bottom) Inputs are not shown.

Comparaison aux concurrents

Concurrents principaux : FSRGAN et PULSE (basés sur les GANs)

Performance : Leurs "Fool Rates" plafonnent autour de **34%** ou moins

Problèmes des GANs :

- **Hallucinations :** Inventent des détails incohérents
- **Changement d'identité :** Le visage généré ne ressemble plus à la personne d'origine
- **Artefacts visuels :** Distorsions dans les yeux ou la bouche
- …

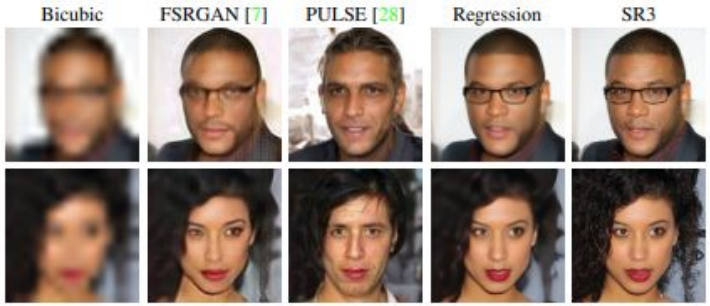

Figure 5: Comparison of different methods on the $16 \times 16 \rightarrow 128 \times 128$ face super-resolution task. Reference image has not been included because of privacy concerns. Additional results in Appendix C.5.

Les points forts

Consistance :

Si on réduit l'image générée par SR3, on retombe presque exactement sur l'image d'entrée, SR3 est bien meilleur que PULSE et FSRGAN sur ce point

Utilité :

Test sur ImageNet : Un classifieur (ResNet-50) reconnaît-il mieux les objets après super-résolution ?

=>Résultat : SR3 réduit le taux d'erreur bien mieux que la régression

Method	Top-1 Error	Top-5 Error
Baseline	0.252	0.080
DRCN [22]	0.477	0.242
FSRCNN [13]	0.437	0.196
PsyCo [35]	0.454	0.224
ENet-E [44]	0.449	0.214
RCAN [64]	0.393	0.167
Regression	0.383	0.173
SR3	**0.317**	**0.120**

Table 3: Comparison of classification accuracy scores for 4× natural image super-resolution on the first 1K images from the ImageNet Validation set.

Exemple de résultats

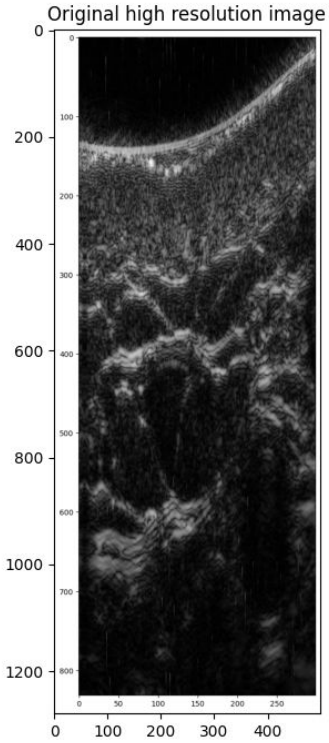

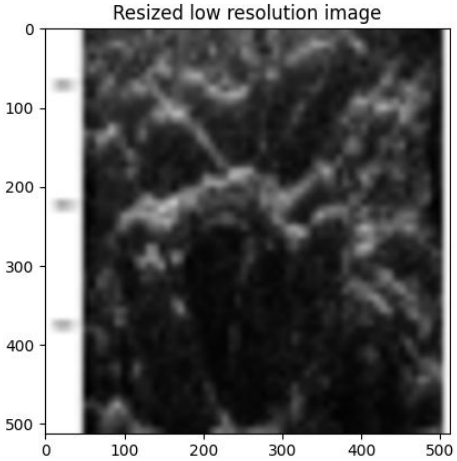

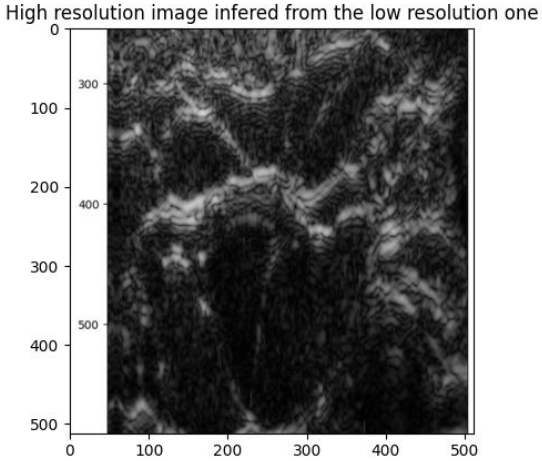

Conclusion

De bons résultats

SR3 utilise une méthode de Super-Résolution par raffinement itératif répété

Innovation : Adaptation réussie des modèles de diffusion à la génération conditionnelle tout en réduisant le nombre de pas par rapport aux précédents modèles de diffusion (2000 pas pour les anciens modèles à 100 pas pour SR3)

=> Converge plus vite

Performance :

- Surpasse les GANs en photoréalisme (Fool Rate ~50%).
- Conserve la fidélité à l'image source (Meilleure consistance que PULSE/FSRGAN).

Flexibilité : Efficace sur les visages et les images naturelles, adaptable via la génération en cascade

Biais et Limites

- **Le problème du lissage :** Tendance à "nettoyer" excessivement. SR3 supprime parfois des détails uniques comme les grains de beauté, boutons, piercings…

- **Biais de données :** Comme tout modèle génératif, il reproduit les biais de son jeu d'entraînement

- **Échecs spécifiques :** Difficultés avec le texte (qui devient net mais illisible) ou les structures très régulières (lunettes sans monture)

- **Avertissement :** Les auteurs déconseillent l'utilisation pour des tâches critiques du monde réel avant résolution de ces biais

Biais et Limites

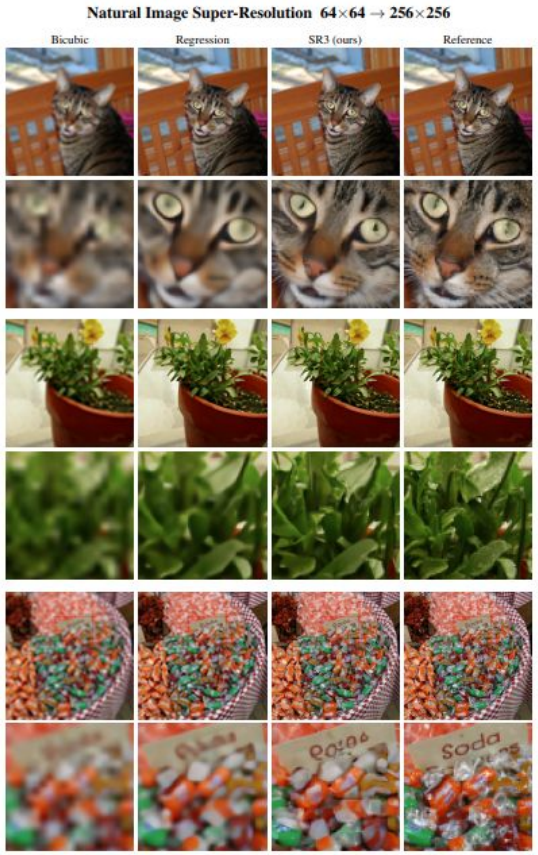

Figure C.3: Additional results of a SR3 model (64×64 → 256×256), trained on ImageNet and evaluated on ImageNet test images.

Figure C.2: Additional results of a SR3 model (64×64 → 512×512), trained on FFHQ, and applied to images outside of the training set. We crop and align these faces to be consistent with FFHQ using the script provided here.

Merci de votre écoute